

Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

Факультет «Фундаментальные науки»
Кафедра ФН-12 «Математическое моделирование»
Группа ФН12-81Б

ОТЧЕТ

Геометрический анализ и целевое дообучение нейросетевой модели перспективного преобразования

Студент:

Чеснокова М.А.

Руководитель:

Виноградова М.С.

Москва, 2026

Содержание

ВВЕДЕНИЕ	3
1 ПОСТАНОВКА ИССЛЕДОВАТЕЛЬСКОЙ ЗАДАЧИ	5
1.1 Перспективное преобразование	5
1.2 Нейросетевая модель	5
1.3 Синтетический датасет	6
2 МЕТОДИКА ИССЛЕДОВАНИЯ	7
2.1 Логика вычислительного исследования	7
2.2 Подготовка признакового пространства	8
2.3 Метод случайных направлений	9
2.4 Контроль корректности вычислительного этапа	10
2.5 Проверка достаточности числа направлений	11
3 ПОЛУЧЕННЫЕ РЕЗУЛЬТАТЫ	12
3.1 Сравнение ошибок на разных группах	12
3.2 Интерпретация абсолютной и относительной ошибки	12
3.3 Характеристика опорных примеров	13
3.4 Пересечение с хвостом ошибок	14
3.5 Предварительная апробация целевого дообучения	15
4 ПРОГРАММНАЯ РЕАЛИЗАЦИЯ	17
4.1 Структура программных файлов	17
4.2 Подготовка аналитических материалов	17
4.3 Воспроизводимость результатов	17
4.4 Ограничения результатов	18
ЗАКЛЮЧЕНИЕ	19
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	20

ВВЕДЕНИЕ

Перспективное преобразование является одной из базовых операций компьютерной графики, компьютерного зрения и геометрического моделирования. Оно описывает переход от исходных точек предметной плоскости к координатам их изображений на картинной плоскости с учетом направления наблюдения, расстояния до плоскости проекции и дополнительного поворота локальной системы координат. В классической постановке такое преобразование задается аналитически, однако при произвольных углах наблюдения итоговые зависимости становятся существенно нелинейными.

Современные методы технического зрения часто используют нейросетевые модели как универсальные аппроксиматоры сложных отображений. Поэтому представляет интерес вопрос о том, насколько надежно нейронная сеть способна воспроизводить геометрическое преобразование без явного включения аналитической формулы в архитектуру. Такая постановка важна для задач, где геометрический модуль должен быть частью более сложной дифференцируемой системы.

При оценке качества модели недостаточно ограничиться средней ошибкой на всей тестовой выборке. Средняя метрика может скрывать локально трудные области входного пространства: большие наклоны направления наблюдения, удаленные от начала координат точки и сочетания признаков, расположенные на периферии распределения. Поэтому в работе используется геометрический подход, основанный на приближенном выделении опорных примеров методом случайных направлений.

Цель работы состоит в исследовании связи между геометрической экстремальностью входных примеров и ошибкой нейросетевой модели перспективного преобразования, а также в предварительной проверке возможности целевого дообучения на таких примерах.

Для достижения цели решаются следующие задачи:

1. Формализовать задачу нейросетевой аппроксимации перспективного преобразования.
2. Построить признаковое пространство, объединяющее координаты исходных точек и угловые параметры.

3. Выделить геометрически опорные примеры методом случайных направлений.
4. Сравнить ошибки модели на всей тестовой выборке, support-группе и non-support-группе.
5. Исследовать связь support-группы с хвостом максимальных абсолютных ошибок.
6. Проверить возможность целевого дообучения модели с использованием геометрически опорных примеров.

1 Постановка исследовательской задачи

1.1 Перспективное преобразование

Перспективная проекция является классической задачей аналитической и вычислительной геометрии [1, 2]. Рассмотрим предметную плоскость F_0 , совпадающую с плоскостью OXY . Исходные точки имеют вид

$$p_i = (x_i, y_i, 0), \quad i = 1, \dots, k.$$

В работе используется $k = 4$, то есть один пример содержит кортеж из четырех исходных точек.

Направление наблюдения задается вектором $\mathbf{l}$, зависящим от углов α и β :

$$\mathbf{l} = \begin{bmatrix} \sin \alpha \\ \sin \alpha \sin \beta \\ \cos \alpha \cos \beta \end{bmatrix}.$$

Точка наблюдения и центр картинной плоскости задаются формулами

$$\mathbf{O} = d_{\text{obs}} \mathbf{l}, \quad \mathbf{C} = d_{\text{proj}} \mathbf{l}.$$

Картинная плоскость ортогональна направлению $\mathbf{l}$ и дополнительно поворачивается вокруг него на угол φ .

Точное перспективное преобразование можно представить как отображение

$$R : \{p_1, \dots, p_k\} \xrightarrow{\alpha, \beta, \varphi} \{p'_1, \dots, p'_k\},$$

где $p'_i = (x'_i, y'_i)$ — координаты проекции в локальной системе координат картинной плоскости.

1.2 Нейросетевая модель

Нейросетевая модель рассматривается как регрессионный аппроксиматор геометрического отображения; общие принципы обучения таких моделей

изложены в [3]. В работе модель задается как функция

$$f_{\theta} : \mathbb{R}^{2k+3} \rightarrow \mathbb{R}^{2k}.$$

При $k = 4$ размер входного вектора равен 11, а размер выходного вектора равен 8. Вход содержит координаты исходных точек и углы преобразования:

$$X = (x_1, \dots, x_4, y_1, \dots, y_4, \alpha, \beta, \varphi).$$

Выход содержит координаты спроецированных точек:

$$Y = (x'_1, \dots, x'_4, y'_1, \dots, y'_4).$$

В качестве основной модели использовалась полносвязная нейросеть с тремя скрытыми слоями по 256 нейронов и функцией активации ReLU. Данная архитектура была выбрана по результатам предварительного сравнения с меньшей моделью, имеющей два скрытых слоя по 32 нейрона.

1.3 Синтетический датасет

Синтетический датасет был сформирован с помощью точного геометрического алгоритма. Координаты исходных точек генерировались равномерно в квадрате $[-1, 1] \times [-1, 1]$. Углы выбирались из диапазонов

$$\alpha, \beta \in [-85^\circ, 85^\circ], \quad \varphi \in [-180^\circ, 180^\circ].$$

Расстояния были зафиксированы:

$$d_{\text{proj}} = 2, \quad d_{\text{obs}} = 4.$$

Обучающая выборка содержит 10 000 000 примеров, тестовая выборка содержит 1 000 000 примеров. Использование синтетического датасета позволило получить точные целевые значения без ошибок ручной разметки и провести статистически устойчивый анализ ошибок.

2 Методика исследования

2.1 Логика вычислительного исследования

Вычислительное исследование строится как последовательность взаимосвязанных этапов. Сначала фиксируется точная геометрическая постановка перспективного преобразования и выбирается нейросетевая модель, которая аппроксимирует это отображение по синтетическим данным. Затем каждый пример тестовой выборки представляется как точка в едином признаковом пространстве, после чего в этом пространстве выделяются геометрически опорные элементы.

Такой порядок важен для интерпретации результатов. Support-группа формируется без использования ошибок модели, то есть определяется только входной геометрией. Уже после этого на найденных примерах рассчитываются MSE, MAE, L2-ошибка и относительная L2-ошибка. Благодаря этому повышенная ошибка может быть связана не с произвольным хвостом метрики, а с конкретным положением примеров относительно множества данных.

Общая логика исследования имеет следующий вид:

1. Задается аналитическое преобразование, по которому формируются целевые значения синтетического датасета.
2. Обученная нейросетевая модель рассматривается как приближенный аппроксиматор этого преобразования.
3. Тестовые примеры переводятся в 14-мерное признаковое пространство.
4. Методом случайных направлений выделяется support-группа.
5. Ошибки модели сравниваются на всей выборке, support-группе и non-support-группе.
6. Найденная геометрически экстремальная область используется для предварительной проверки целевого дообучения.

Особое внимание было уделено различию между обычным анализом ошибок и геометрическим анализом. Обычные метрики показывают среднее качество модели, но не объясняют, где именно во входном пространстве

возникают трудные случаи. Геометрический подход позволяет связать ошибку модели с положением примера относительно всего множества данных.

В отличие от анализа по отдельным признакам, например только по углу α или радиусу исходной точки, метод случайных направлений учитывает линейные комбинации всех признаков. Поэтому он способен выделять такие конфигурации, которые не являются экстремальными по одной координате, но оказываются граничными в совокупном многомерном пространстве. Именно это делает метод удобным для диагностики нейросетевой аппроксимации сложного геометрического отображения.

2.2 Подготовка признакового пространства

Для применения метода случайных направлений каждый пример датасета был представлен как точка в многомерном пространстве признаков. Координаты исходных точек использовались непосредственно, а углы кодировались через синус и косинус:

$$\alpha \mapsto (\sin \alpha, \cos \alpha), \quad \beta \mapsto (\sin \beta, \cos \beta), \quad \varphi \mapsto (\sin \varphi, \cos \varphi).$$

Итоговый признаковый вектор имеет вид

$$Z = [x_1, \dots, x_4, y_1, \dots, y_4, \sin \alpha, \cos \alpha, \sin \beta, \cos \beta, \sin \varphi, \cos \varphi].$$

Его размерность равна 14.

Такое представление было выбрано по двум причинам. Во-первых, оно устраняет разрыв периодичности углов. Во-вторых, все признаки оказываются в сопоставимом диапазоне значений, что важно для метода случайных направлений.

Прямое использование углов в градусах или радианах в качестве линейных признаков было бы менее удачным. Например, значения угла φ около -180° и 180° геометрически близки, но в обычном числовом представлении оказываются расположены на разных концах интервала. Синусно-косинусное кодирование устраняет этот искусственный разрыв и сохраняет циклическую природу угловой переменной.

Координаты исходных точек не требуют дополнительного масштаби-

рования, поскольку уже генерируются в диапазоне $[-1, 1]$. Поэтому итоговое пространство признаков имеет достаточно однородный масштаб: координатные компоненты, синусы и косинусы принимают значения одного порядка. Это снижает риск того, что метод случайных направлений будет фактически определяться только одной группой признаков.

2.3 Метод случайных направлений

Метод случайных направлений использовался для приближенного выделения геометрически опорных примеров. Его применение связано со свойством опорной функции выпуклого множества и дополняет классические методы построения выпуклой оболочки [1, 4]. Для случайного единичного вектора v выбирался пример, максимизирующий скалярное произведение:

$$i^* = \arg \max_i \langle Z_i, v \rangle.$$

Повторение этой процедуры для большого числа направлений дает множество индексов, соответствующих граничным элементам распределения данных.

Были проведены расчеты для разного числа случайных направлений. Результаты приведены в таблице 1.

Таблица 1 – Число опорных примеров при разном числе направлений

Число направлений	Опорных примеров	Доля тестовой выборки, %
500	496	0.0496
1000	979	0.0979
2000	1927	0.1927
5000	4609	0.4609
10000	8669	0.8669
20000	15638	1.5638
50000	32028	3.2028
100000	52079	5.2079
200000	80620	8.0620

Для дальнейшего анализа использовался вариант с 200000 направлениями. Расширенный прогон показал, что при 5000 направлениях оболочка еще не стабилизирована: при переходе к 200000 направлениям число найденных support-примеров возрастает с 4609 до 80620. Эта зависимость дополнительно

представлена на рисунке 1.



Рисунок 1 – Рост числа опорных примеров при увеличении числа случайных направлений

2.4 Контроль корректности вычислительного этапа

До интерпретации результатов были проверены условия, без которых сравнение групп могло бы оказаться некорректным. Размер тестового массива был зафиксирован равным 1 000 000 строк, а порядок примеров не изменялся после построения support-индексов. Для каждого набора направлений проверялось, что каждый найденный индекс принадлежит допустимому диапазону и что размер объединения support и non-support совпадает с размером тестовой выборки.

При построении признакового пространства контролировались единицы измерения углов. Тригонометрическое кодирование выполнялось после перевода углов в радианы; иначе значения синуса и косинуса не соответствовали бы геометрическим параметрам исходной постановки. Дополнительно учитывалось, что все координатные и угловые компоненты после преобразования принадлежат сопоставимым диапазонам значений.

Для расчета групповых метрик использовались одни и те же предсказания базовой модели. Такой порядок исключает влияние переобучения или повторного случайного запуска на сравнение support и non-support. В итоге геометри-

ческий этап отвечает на вопрос о положении примеров в пространстве входов, а последующая оценка ошибок — на вопрос о поведении фиксированной модели в выделенной области.

2.5 Проверка достаточности числа направлений

Расширение числа направлений стало существенной частью исследования, поскольку размер тестовой выборки значительно превышает размер пилотной support-группы. Для вложенной последовательности наборов направлений был рассчитан не только общий размер support-группы, но и число новых примеров, появившихся при расширении прогона.

Таблица 2 – Прирост support-группы при расширении числа направлений

Переход	Было примеров	Стало примеров	Новых примеров
5000 → 10000	4609	8669	4060
10000 → 20000	8669	15638	6969
20000 → 50000	15638	32028	16390
50000 → 100000	32028	52079	20051
100000 → 200000	52079	80620	28541

Полученные значения показывают, что множество опорных примеров в исследованном диапазоне не вышло на плато. Последний переход добавляет 28541 ранее не найденный пример. Поэтому результат с 5000 направлениями может использоваться только как предварительный эксперимент, а основным результатом принимается анализ при 200000 направлениях. При этом утверждение о полном восстановлении вершин выпуклой оболочки не делается: метод сохраняет приближенный характер.

Важный вывод состоит в том, что увеличение числа направлений меняет не только размер support-группы, но и смысл дальнейшей интерпретации. При 5000 направлениях выделяется очень узкая периферийная область, составляющая менее половины процента тестовой выборки. При 200000 направлениях область становится шире и охватывает 8.062% примеров, однако по-прежнему остается достаточно малой по отношению ко всему датасету. Поэтому дальнейший анализ проводится для расширенной группы: она лучше отражает геометрию границы множества данных и меньше зависит от случайности небольшого числа направлений.

3 Полученные результаты

3.1 Сравнение ошибок на разных группах

После выделения support-группы были вычислены ошибки базовой модели на всей тестовой выборке, на опорных примерах и на неопорных примерах. Результаты приведены в таблице 3.

Таблица 3 – Ошибки модели на группах тестовой выборки

Группа	N	MSE	MAE	L2	RelL2 med.
Все примеры	1 000 000	0.000144814	0.00943234	0.03255993	0.04984633
Опорные	80 620	0.000183517	0.01059331	0.03664523	0.04829143
Неопорные	919 380	0.000141420	0.00933053	0.03220169	0.04998508

Опорные примеры имеют более высокую абсолютную ошибку. MSE на support-группе выше средней MSE по всей тестовой выборке примерно на 26.7%, а MAE выше примерно на 12.3%. При этом медианная относительная L2-ошибка практически не увеличивается.

Данный результат показывает, что геометрически экстремальная область действительно связана с повышенной абсолютной ошибкой модели. Однако относительная ошибка остается сопоставимой, поскольку в этой области увеличивается масштаб выходных координат.

3.2 Интерпретация абсолютной и относительной ошибки

Различие между абсолютной и относительной ошибкой важно для понимания полученного результата. Перспективное преобразование изменяет масштаб выходных координат в зависимости от положения исходных точек и углов наблюдения. Поэтому в геометрически экстремальной области абсолютное отклонение может возрастать даже тогда, когда относительная точность модели остается близкой к средней по тестовой выборке.

В рассматриваемом эксперименте support-группа имеет более высокие MSE, MAE и L2-ошибку, но медианная относительная L2-ошибка не увеличивается. Это означает, что модель не демонстрирует катастрофического ухудшения в найденной области. Скорее, абсолютная ошибка растет вместе с масштабом целевого выходного вектора. Такой вывод важен для прикладной

интерпретации: если в задаче критична абсолютная точность координат, support-группа требует дополнительного внимания; если же важна относительная точность по отношению к масштабу результата, поведение модели оказывается более устойчивым.

Тем не менее повышенная абсолютная ошибка остается значимым диагностическим сигналом. В задачах компьютерного зрения даже небольшое абсолютное смещение ключевых точек может влиять на последующие этапы обработки, например на оценку положения объекта или восстановление геометрических параметров сцены. Поэтому выделение граничных примеров методом случайных направлений позволяет заранее определить область, для которой целесообразно проводить отдельный контроль качества.

3.3 Характеристика опорных примеров

Для объяснения природы support-группы были сравнены распределения признаков у всех тестовых примеров и у опорных примеров. Основные результаты приведены в таблице 4.

Таблица 4 – Характеристики всех и опорных примеров

Признак	Med. all	Med. support	Q95 all	Q95 support
Макс. радиус точки	1.048362	1.205958	1.308747	1.358780
Средний радиус точек	0.772041	0.934008	0.975858	1.076895
$ \alpha $, град.	40.783455	57.359749	80.641991	83.642784
$ \beta $, град.	41.852951	57.510555	81.141174	83.879929
$ \varphi $, град.	90.504456	90.599174	171.129166	172.071060

Из таблицы видно, что support-группа характеризуется большими значениями $|\alpha|$ и $|\beta|$, а также более удаленными от начала координат исходными точками. Угол φ выраженно не отделяет опорные примеры от всей выборки. Распределения для углов $|\alpha|$ и $|\beta|$ показаны на рисунках 2 и 3.




Рисунок 2 – Распределение $|\alpha|$ для всех и опорных примеров




Рисунок 3 – Распределение $|\beta|$ для всех и опорных примеров

3.4 Пересечение с хвостом ошибок

Дополнительно было проверено, как часто опорные примеры попадают в хвост максимальных ошибок базовой модели. Базовая доля опорных примеров во всей тестовой выборке при 200000 направлениях равна 8.062%.

Таблица 5 – Пересечение опорных примеров с хвостом MSE

Top MSE	Число опорных	Доля, %	Обогащение
0.1%	299 из 1000	29.90%	3.71
0.5%	1246 из 5000	24.92%	3.09
1%	2319 из 10000	23.19%	2.88
5%	9062 из 50000	18.12%	2.25
10%	15791 из 100000	15.79%	1.96

Опорные примеры попадают в хвост абсолютной ошибки существенно чаще, чем ожидалось бы при случайном выборе. Для top-1% по MSE их доля равна 23.19%, что примерно в 2.88 раза выше базовой доли. Следовательно, геометрическая экстремальность связана с повышенной ошибкой модели, хотя не является полным эквивалентом отбора по максимальной ошибке. Графически этот эффект представлен на рисунке 4.




Рисунок 4 – Обогащение хвоста ошибок опорными примерами

3.5 Предварительная апробация целевого дообучения

После обнаружения области повышенной абсолютной ошибки была выполнена ограниченная апробация идеи целевого дообучения. На этом этапе проверялся основной вопрос: возможно ли использовать геометрически выделенные примеры как целевой компонент обучающей смеси. Детальное сравнение хвостов ошибок и интерпретация стратегии обучения требуют отдельного ана-

лиза, поэтому здесь рассматривается только сводный результат по нескольким долям support-примеров.

Для дообучения использовалась базовая модель после 25-й эпохи. Из обучающей выборки формировался pool объемом 120 000 примеров, в котором опорные элементы также выделялись при 200000 случайных направлениях. Были проверены смеси с долями support-примеров 0%, 10%, 20% и 30%. Каждый вариант запускался для трех значений seed: 101, 202 и 303.

Таблица 6 – Краткие результаты дообучения по трем запускам

Support, %	MSE all	MSE support	MAE support
0	0.000076228	0.000093938	0.007553682
10	0.000075965	0.000093026	0.007517341
20	0.000075879	0.000092368	0.007492259
30	0.000076151	0.000092196	0.007487865

По результатам апробации добавление support-примеров не привело к потере качества на всей выборке: минимальное среднее значение MSE на всех примерах получено при доле 20%. Минимальное среднее значение MSE на support-группе достигнуто при доле 30%. Различие между режимами 20% и 30% на support-группе невелико, поэтому в качестве практического компромисса для дальнейшей интерпретации рассматривается диапазон 20–30%.

Таким образом, геометрический анализ был дополнен экспериментальной проверкой возможности использовать выделенную область при уточнении модели. Полученный результат показывает, что support-примеры могут рассматриваться не только как диагностическая группа, но и как источник целевого сигнала для дообучения.

4 Программная реализация

4.1 Структура программных файлов

В вычислительных экспериментах использовались следующие программные файлы:

- `geometric_error_analysis.py` — построение признаков, поиск опорных примеров и базовое сравнение ошибок;
- `geometric_error_deep_dive.py` — дополнительный анализ ошибок, квантилей и зависимости от нормы выхода;
- `geometric_error_plots.py` — построение графиков для геометрического анализа;
- `geometric_error_overlap.py` — анализ пересечения support-группы с хвостами ошибок;
- `geometric_finetune.py` — подготовка экспериментов по дообучению модели.

Результаты расчетов сохранялись в папках `geometric_analysis_results` и `geometric_finetune_results`. Табличные результаты представлены в форматах CSV и JSON, графики — в формате PNG.

4.2 Подготовка аналитических материалов

По итогам расчетов были подготовлены таблицы и рисунки, отражающие основную часть геометрического анализа: выделение support-группы, сравнение ошибок, пересечение с хвостом ошибок и краткую апробацию целевого дообучения. Отдельно сохранялись промежуточные CSV- и JSON-файлы, чтобы численные значения можно было проверить без ручного переноса данных из графиков.

4.3 Воспроизводимость результатов

Материалы исследования организованы таким образом, чтобы расчетные этапы можно было повторять независимо друг от друга. Исходный датасет хра-

нится в формате HDF5, удобном для чтения больших массивов без ручного преобразования. Индексы support-примеров, сводные метрики и параметры запусков сохраняются отдельно, поэтому графики и таблицы могут быть перестроены без повторного обучения базовой модели.

При повторении геометрического анализа необходимо сохранить порядок строк тестового датасета, единицы измерения углов и значение seed, используемое для генерации направлений. При повторении дообучения дополнительно должны быть зафиксированы исходные веса модели, состав train-pool, число эпох и доля support-примеров в смеси. Эти условия позволяют отличать изменение исследуемого метода от случайного изменения входных данных.

Полученные файлы разделены по назначению: программы отвечают за расчет, CSV- и JSON-файлы содержат числовые итоги и параметры запусков, PNG-файлы используются для включения в отчет. Такая организация обеспечивает прозрачную связь между вычислением, числовым результатом и его представлением в пояснительной записке.

4.4 Ограничения результатов

Проведенное исследование имеет ограничения, которые необходимо учитывать при интерпретации результатов. Во-первых, выделение опорных примеров методом случайных направлений является приближенным; расширенный прогон показал отсутствие плато до 200000 направлений. Во-вторых, анализ выполнен на синтетическом датасете, где отсутствуют шум измерений и ошибки детектирования точек, характерные для реальных изображений. В-третьих, проверен один основной вариант архитектуры нейронной сети.

Эти ограничения не отменяют полученных выводов, поскольку исследование выполнялось в контролируемой синтетической постановке и было направлено на выявление связи между входной геометрией и ошибкой модели. В дальнейшем подход может быть расширен за счет других архитектур, иных способов нормализации признаков и проверки на реальных данных.

ЗАКЛЮЧЕНИЕ

В работе была рассмотрена задача геометрического анализа ошибок нейросетевой аппроксимации перспективного преобразования. Для этого была формализована постановка преобразования, описана структура синтетического датасета и рассмотрена полносвязная нейросетевая модель, отображающая координаты исходных точек и углы преобразования в координаты проекции.

Основным результатом стало проведение геометрического анализа ошибок нейросетевой модели методом случайных направлений. Было построено 14-мерное признаковое пространство, в котором один пример датасета рассматривается как точка. При использовании 200000 случайных направлений на тестовой выборке из 1 000 000 примеров было найдено 80620 геометрически опорных примеров.

Показано, что опорные примеры имеют повышенную абсолютную ошибку: MSE на support-группе составил 0.000183517 против 0.000144814 на всей тестовой выборке. Также установлено, что support-группа характеризуется большими значениями $|\alpha|$, $|\beta|$ и большими радиусами исходных точек.

Дополнительно выявлено, что опорные примеры непропорционально часто попадают в хвост максимальных ошибок модели. В top-1% по MSE доля support-примеров составляет 23.19%, что примерно в 2.88 раза выше их базовой доли. Это подтверждает связь геометрически экстремальных областей входного пространства с повышенной ошибкой нейросетевой аппроксимации.

Дополнительно была выполнена предварительная проверка целевого дообучения. Результаты показывают, что усиление геометрически опорных примеров в обучающей смеси может улучшать качество модели на support-группе. Таким образом, метод случайных направлений может использоваться не только как диагностический инструмент, но и как основа для формирования целевой выборки дообучения.

Список литературы

- [1] de Berg M., Cheong O., van Kreveld M., Overmars M. *Computational Geometry: Algorithms and Applications*. Springer, 2008. 386 с.
- [2] Юнг Дж. *Проективная геометрия*. Москва, 1949. 185 с.
- [3] Гудфеллоу Я., Бенджио И., Курвилль А. *Глубокое обучение*. MIT Press, 2017. 652 с.
- [4] Barber C. B., Dobkin D. P., Huhdanpaa H. The Quickhull Algorithm for Convex Hulls. *ACM Transactions on Mathematical Software*, 1996. Vol. 22, No. 4. С. 469–483.